



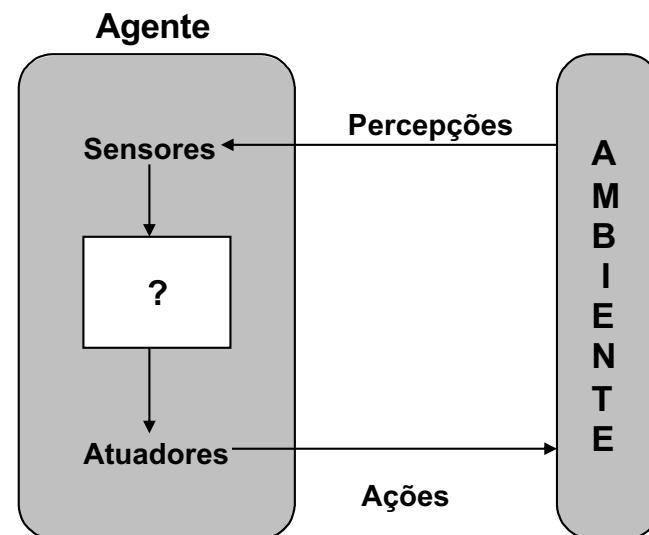
Inteligência Artificial

Evandro de Barros Costa
evandro@ic.ufal.br

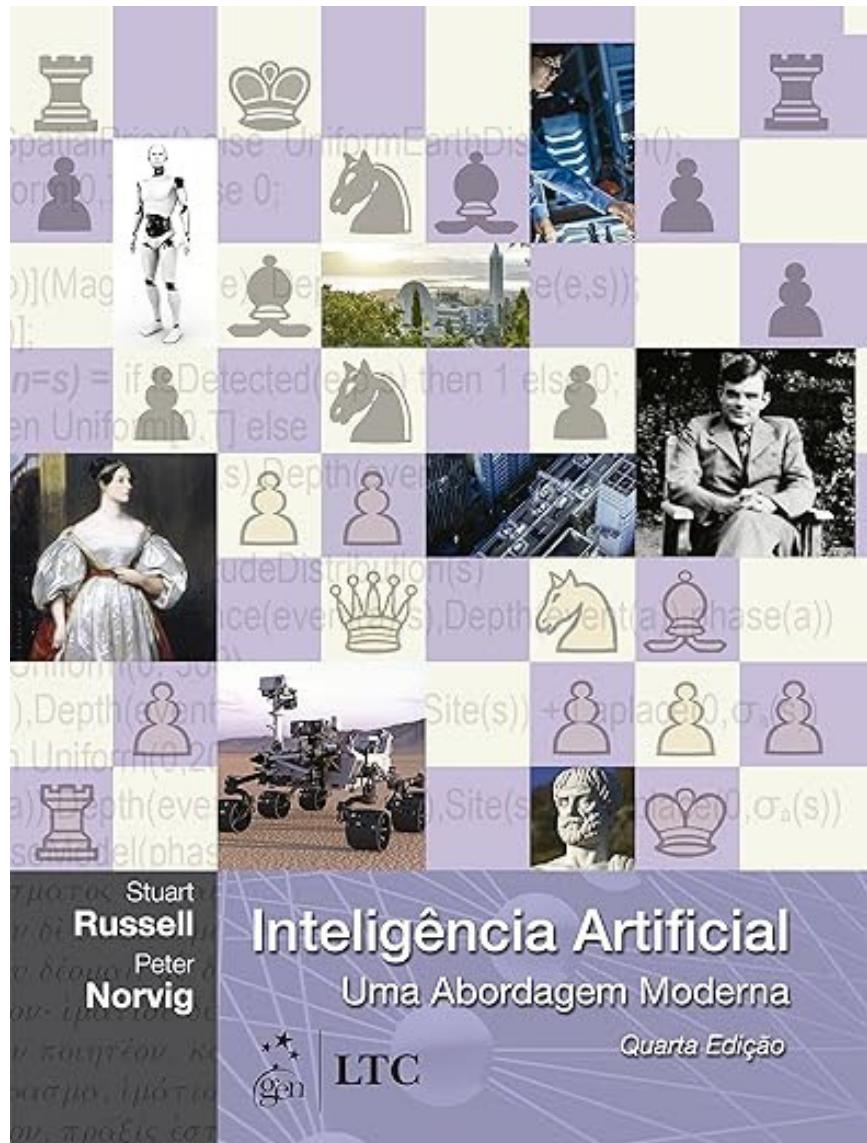
Maceió, Alagoas
Janeiro, 2025

O que é Inteligência Artificial?

Resposta: “Veja o que tem livro do slide seguinte ...”



(S. Russell e P. Norvig, 2020)



Livro de IA: Stuart Russell and Peter Norvig,

Artificial Intelligence: A Modern Approach Fourth Edition, 2020

Inteligência Artificial
Uma Abordagem Moderna

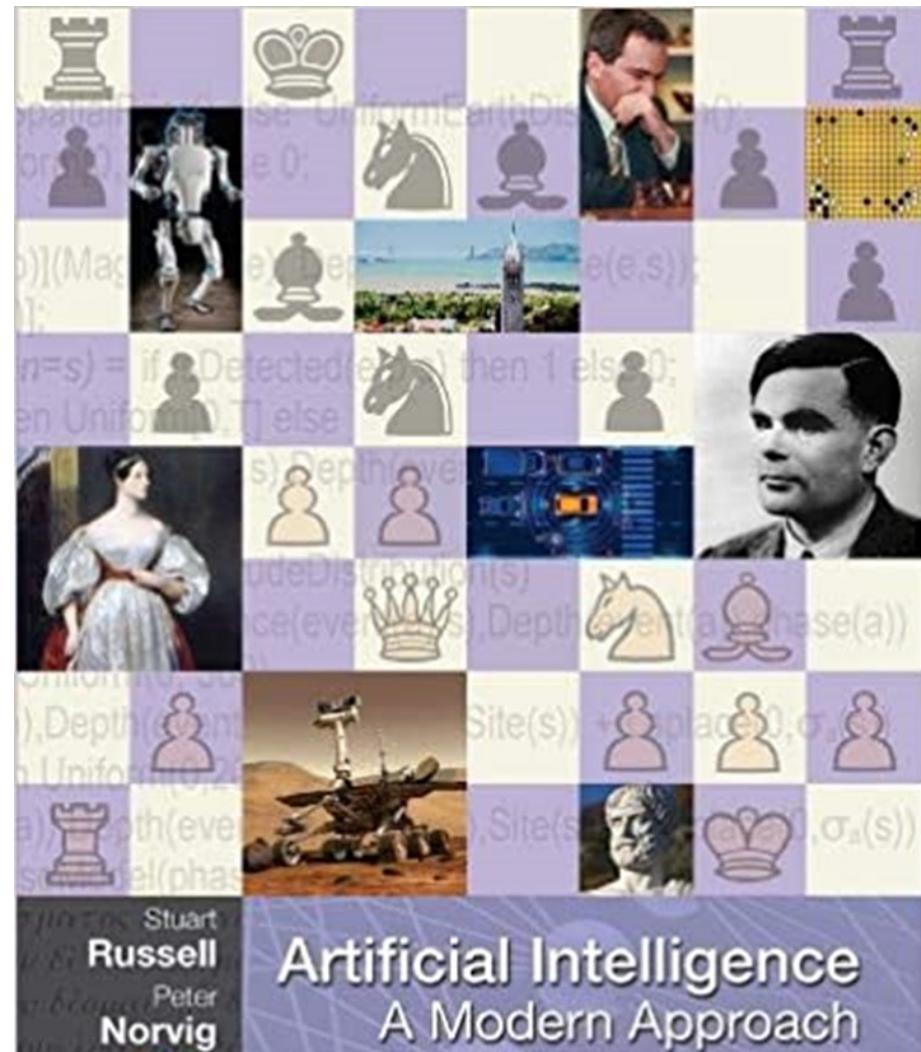
Stuart
Russell
Peter
Norvig

gen | LTC

Quarta Edição

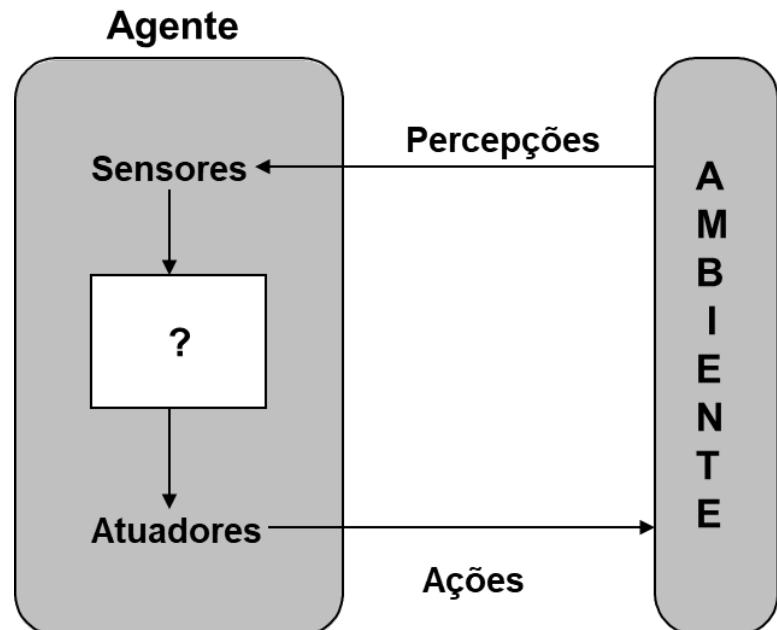
O QUE É INTELIGÊNCIA ARTIFICIAL (IA)?

- Estudo de agentes que recebem percepções do ambiente e realiza ações nesse ambiente;
 - Livro de IA: **Stuart Russell and Peter Norvig, Artificial Intelligence: A Modern Approach Fourth Edition, 2020.**

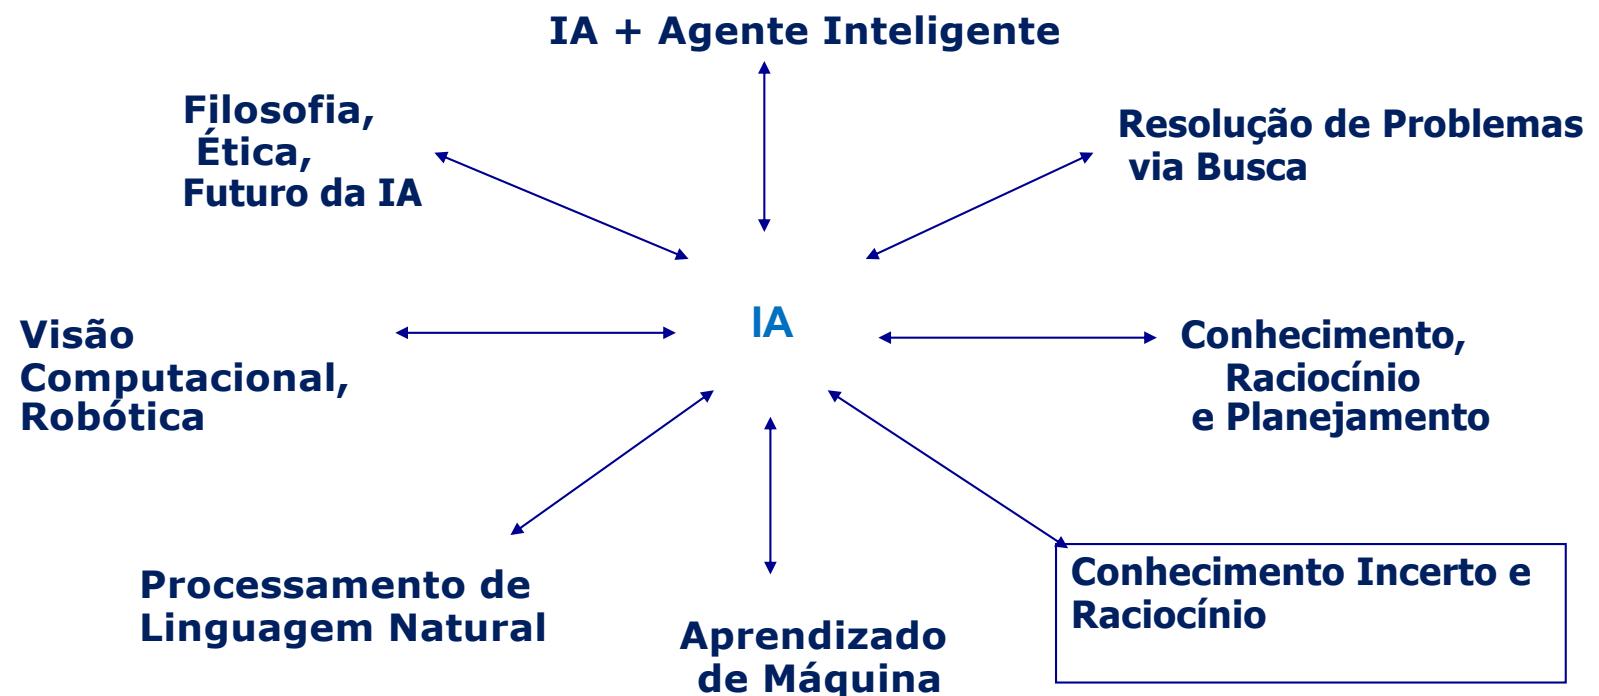


O QUE É INTELIGÊNCIA ARTIFICIAL (IA)?

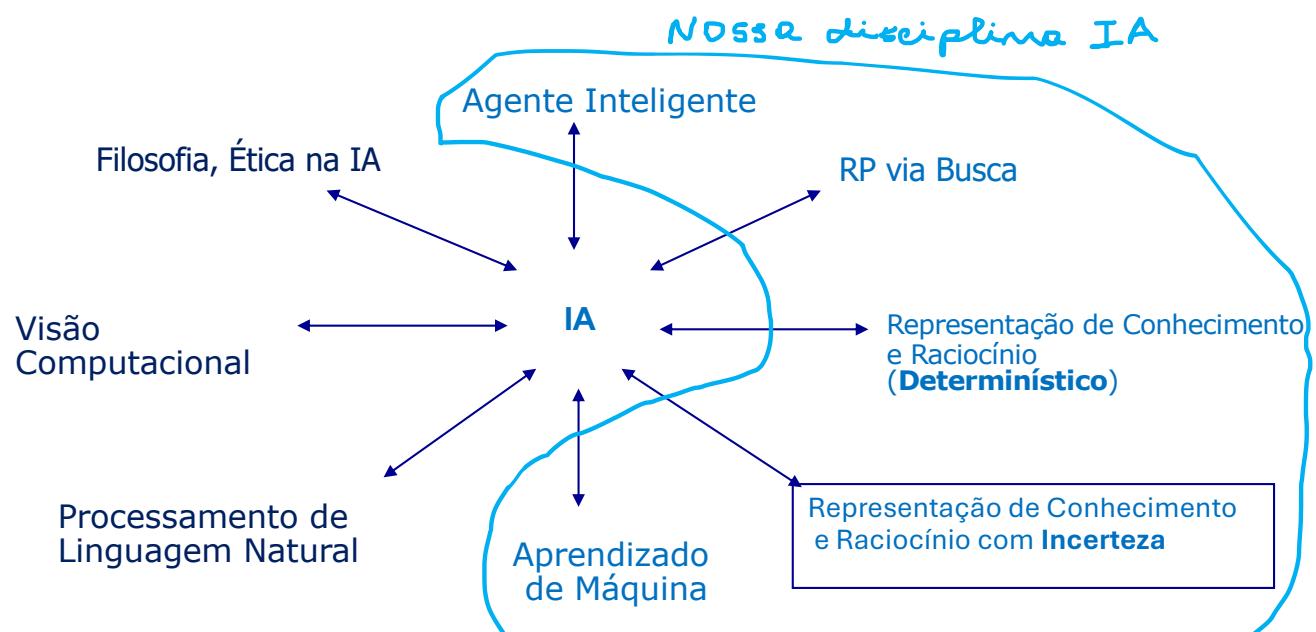
- **ESTUDO DE AGENTES QUE RECEBEM PERCEPÇÕES DO AMBIENTE E REALIZA AÇÕES NESSE AMBIENTE.**



Roteiro do Livro



Disciplina de IA = “Recorte” do Livro de IA, AIMA – Y + X



X = ? Y = ?

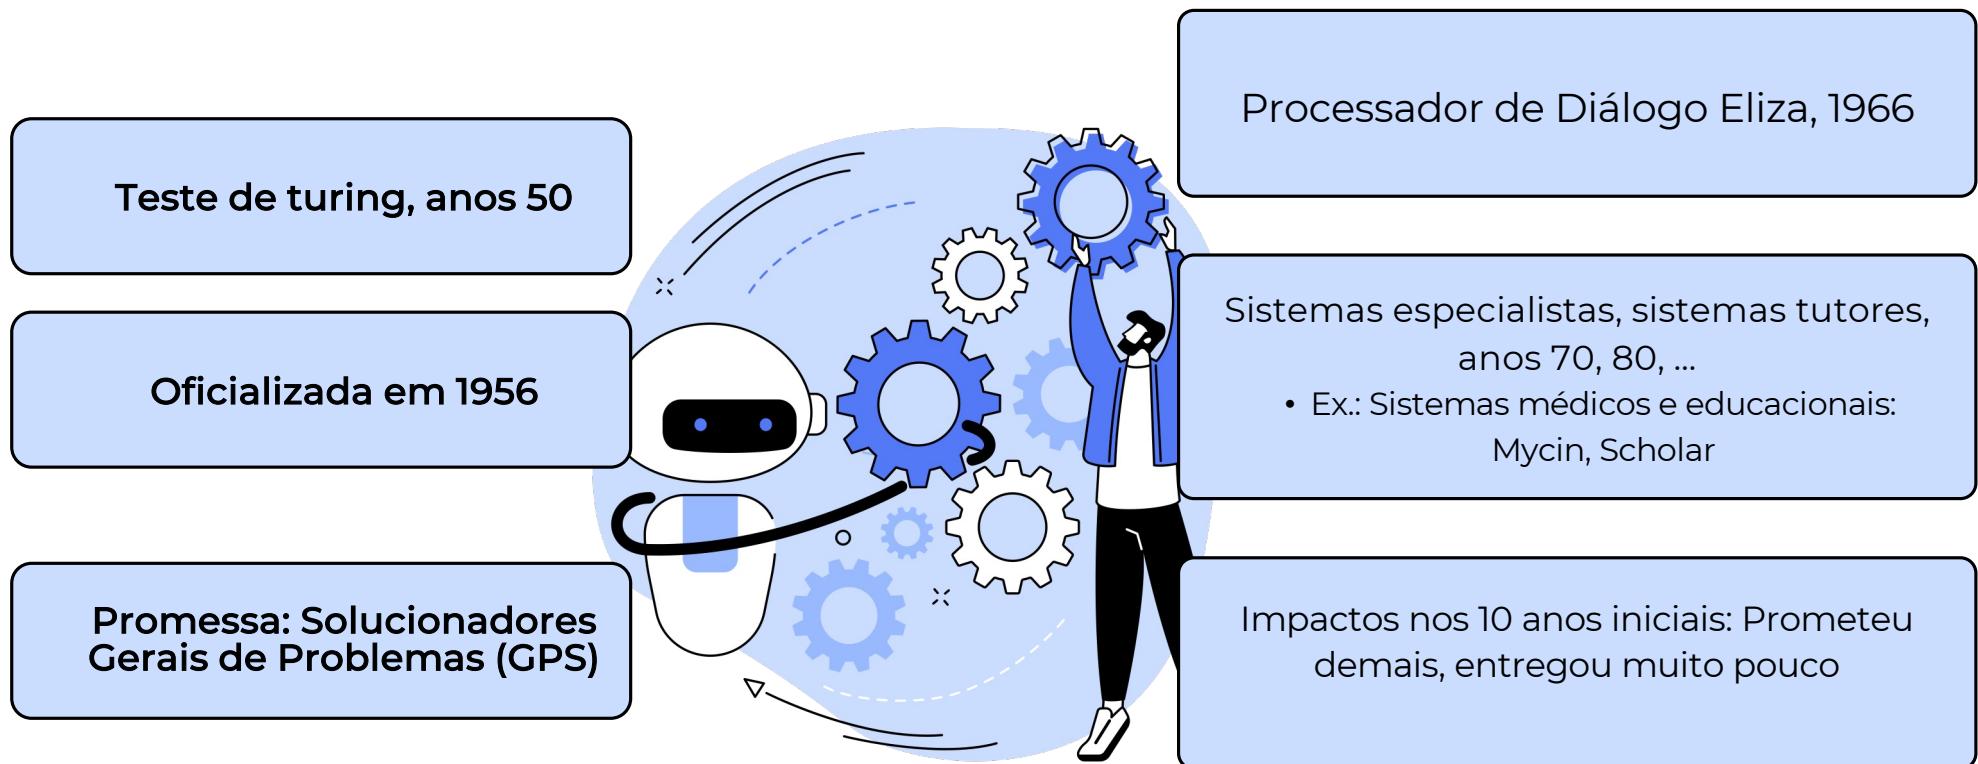
MAS, O QUE É IA?

Sistemas capazes de simular comportamentos inteligentes;

- “IA objetiva desenvolver sistemas computacionais inteligentes, isto é, sistemas que exibem características, as quais nós associamos com a inteligência no comportamento humano”.
 - Ex.: compreensão da linguagem, aprendizado, raciocínio, resolução de problemas
- Agentes computacionais realizando tarefas que normalmente exigiriam inteligência humana, tais como: raciocinar, aprender, tomar decisões, prever situações futuras ou entender e gerar linguagem natural.



INTELIGÊNCIA ARTIFICIAL (IA): INÍCIO



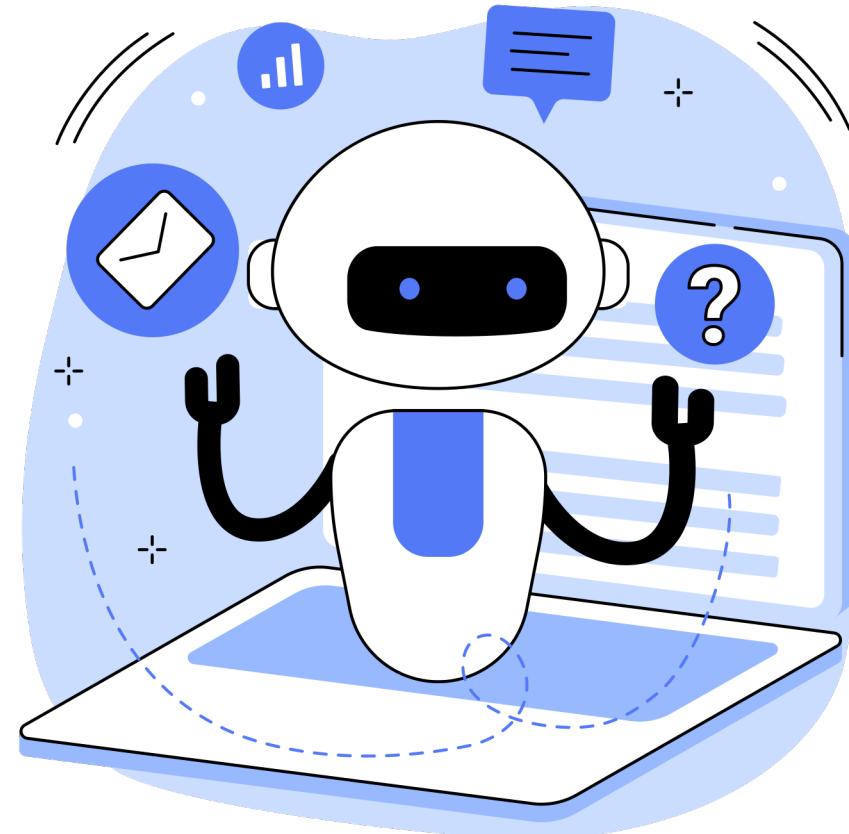
INTELIGÊNCIA ARTIFICIAL

“Parecer-se Inteligente”

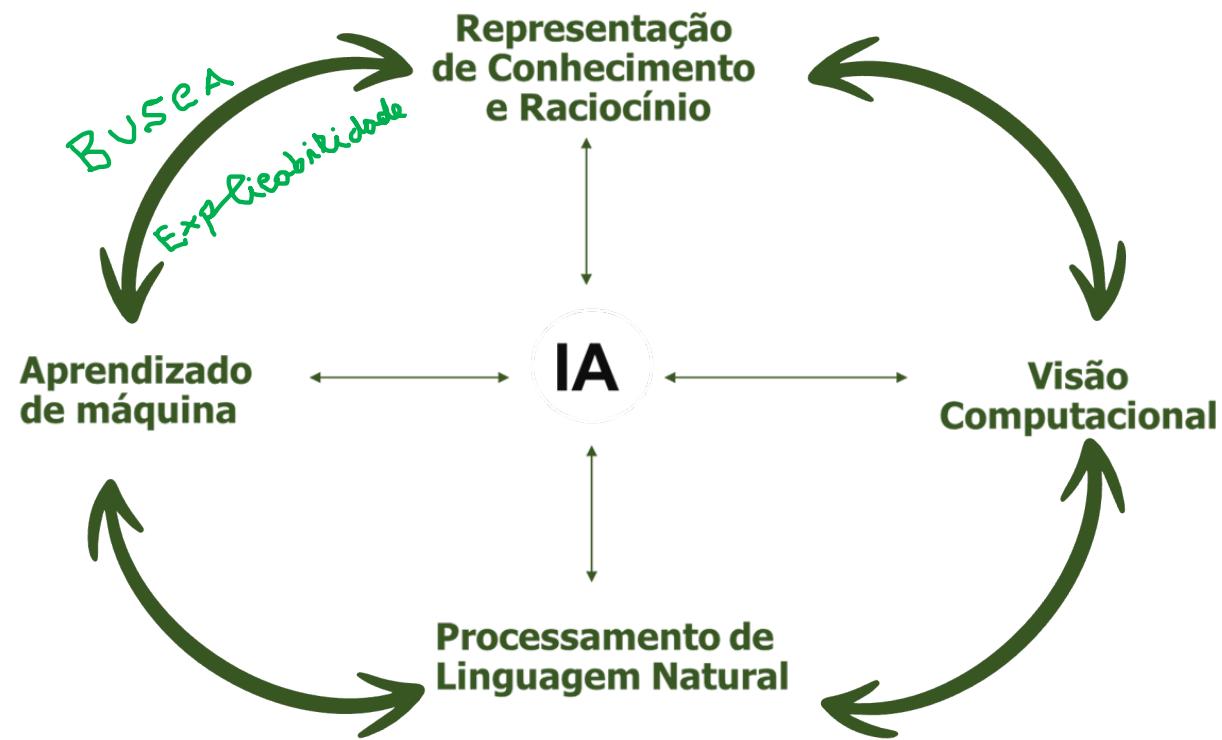
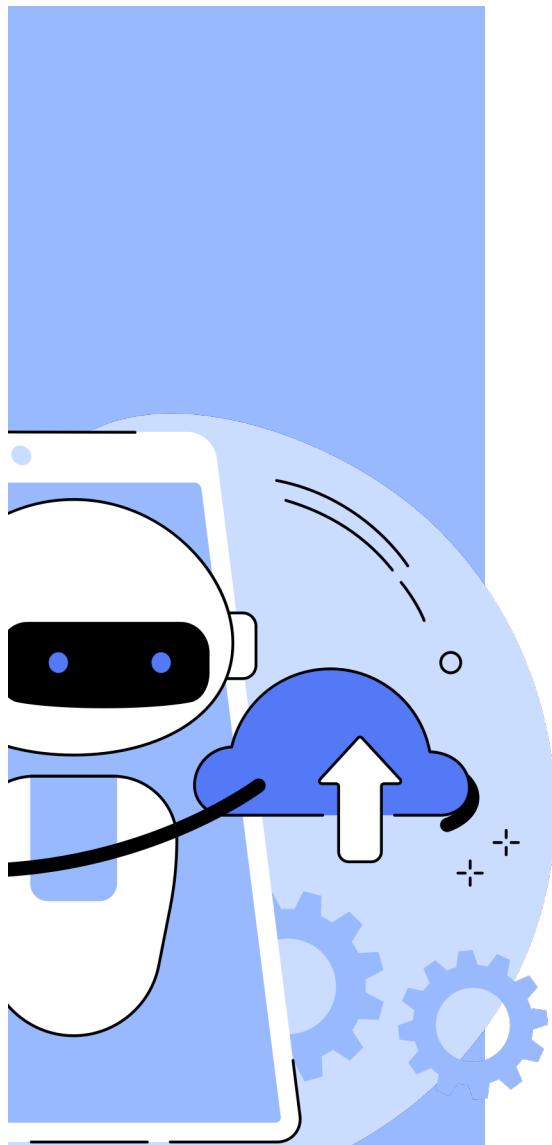
Uma interpretação

Do Teste de Turing ao Eliza

Do Eliza aos chatterbots ... LLMs



AMPLIANDO A ENGRANGEM PARA IA



Um Problema Motivador

Suponha que um gerente de um determinado banco, contratasse você, para desenvolver um Sistema Inteligente para cumprir a tarefa de decidir sobre o nível de risco oferecido por usuários que buscam empréstimo de dinheiro, a cada demanda de seus clientes.

Considere 3 categorias de risco na **classificação** dos clientes: **Alto**, **Moderado** e **Baixo**.

Em Busca da Solução

- Do ponto de vista técnico e agora já sabendo que se trata de uma tarefa de **Classificação**, envolvendo **aprendizado de máquina** (Machine Learning), por onde iniciar?
- O que você perguntaria ao gerente, ou similar?



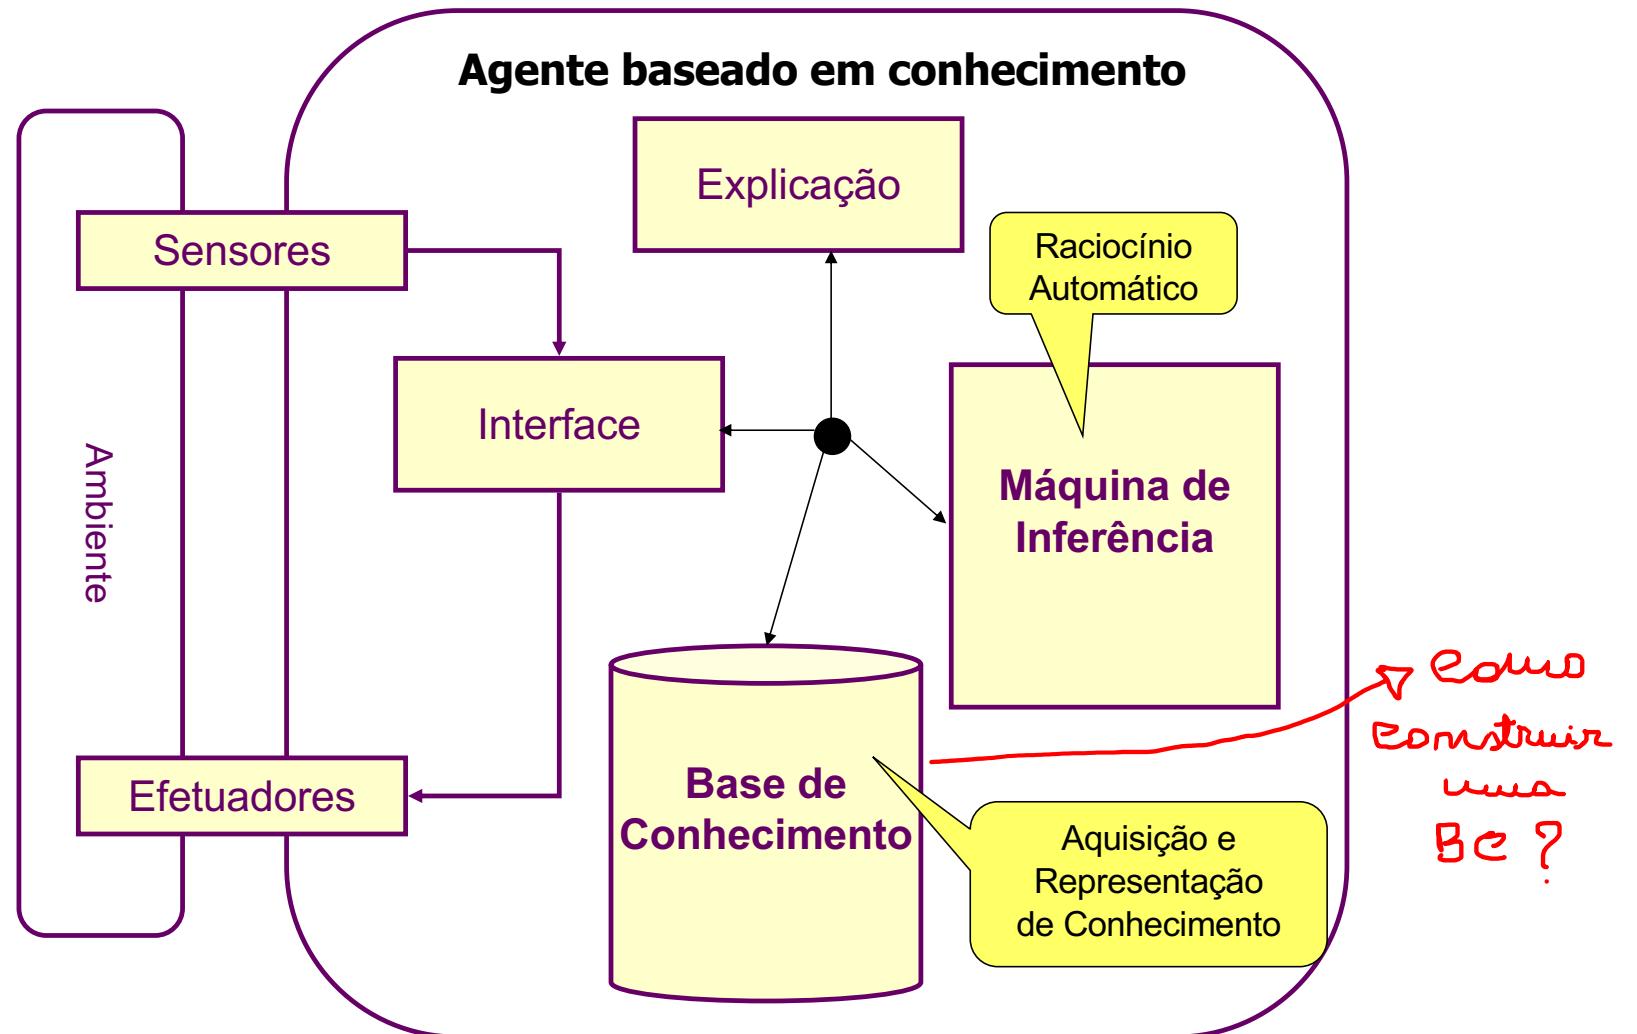
Universidade Federal de Alagoas – UFAL
Instituto de Computação – IC

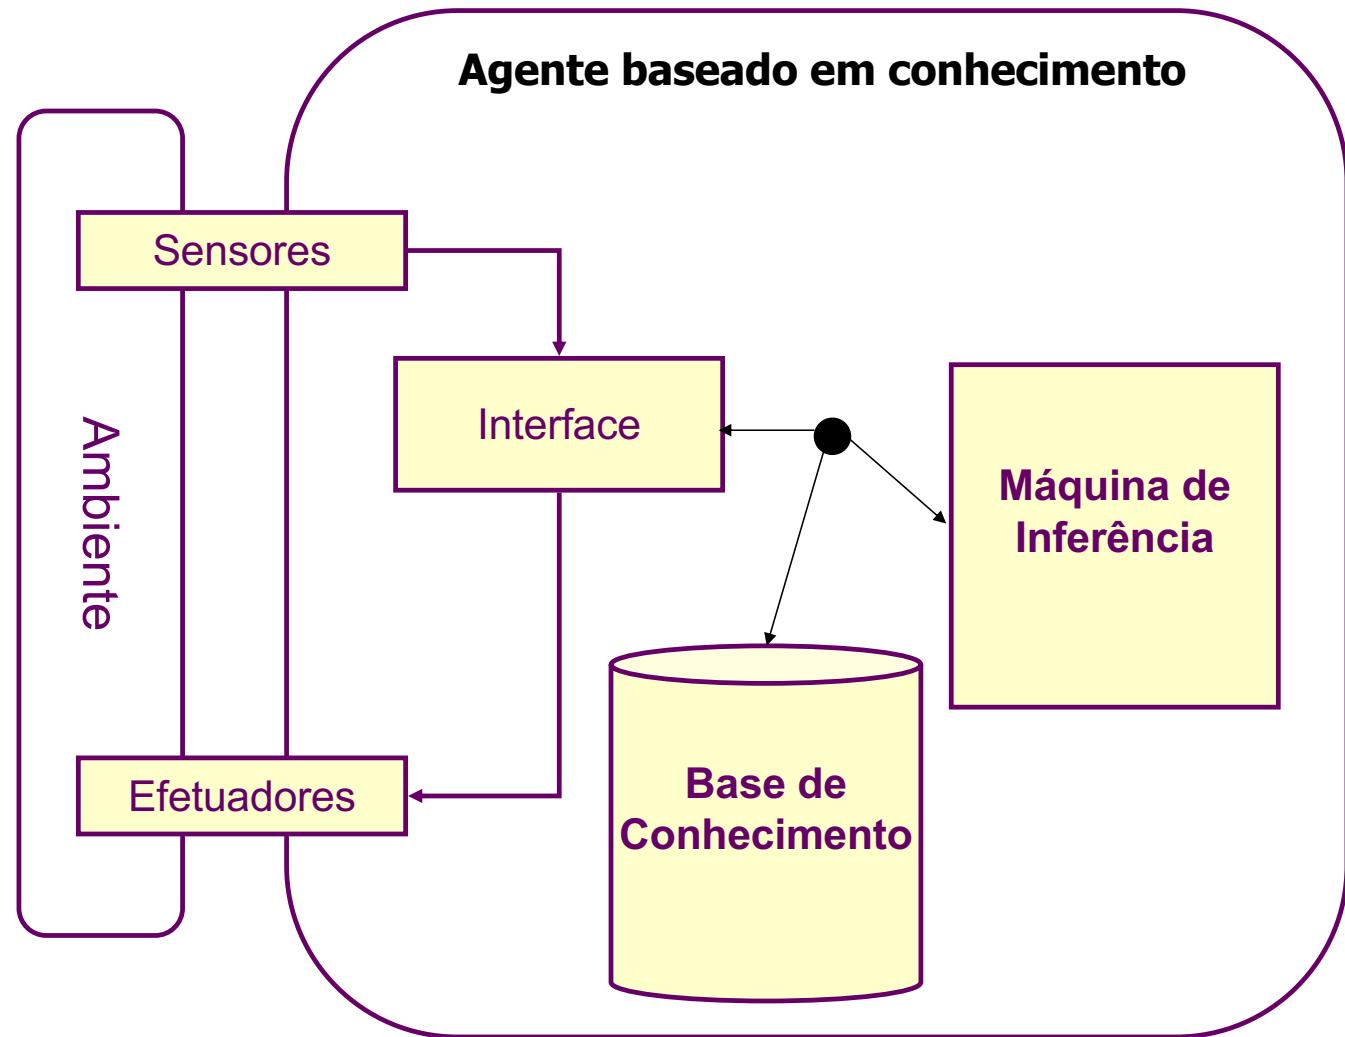
Aprendizagem de Máquina e **Base de Conhecimento**:

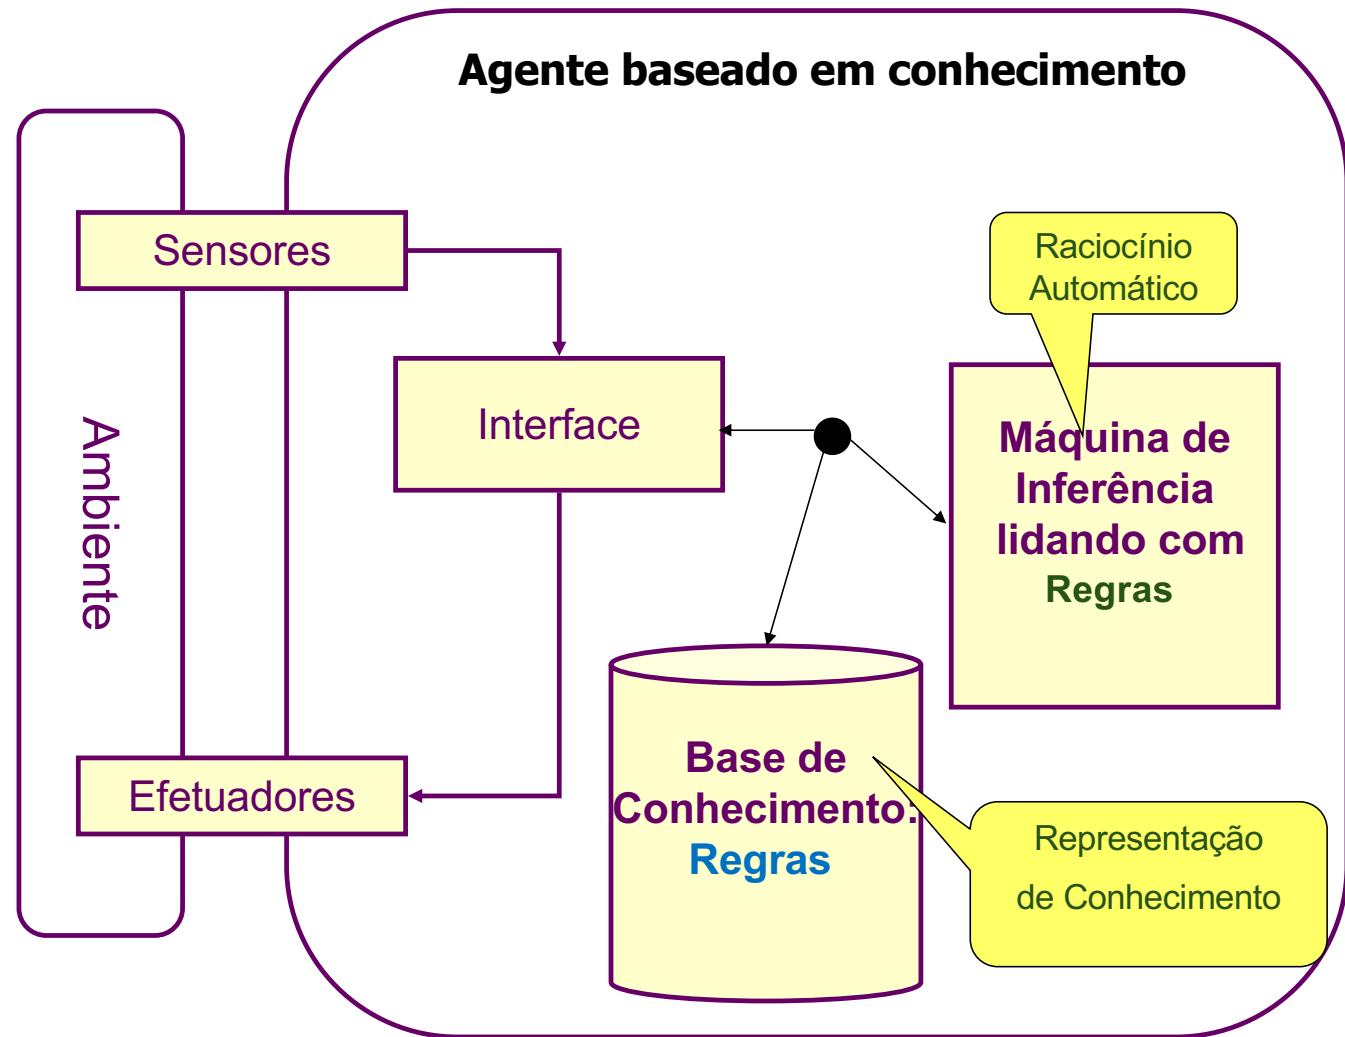
Aprendizagem de Árvore de Decisão

Evandro de Barros Costa
evandro@ic.ufal.br

Maceió, Alagoas
Maio, 2025

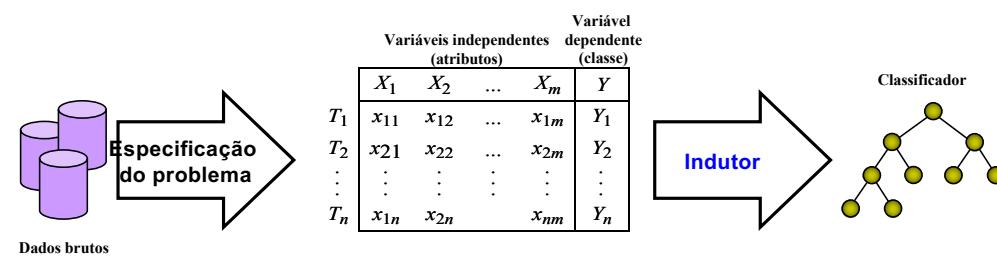






AM via Indução de Árvore de Decisão

- Indução de Árvore de Decisão



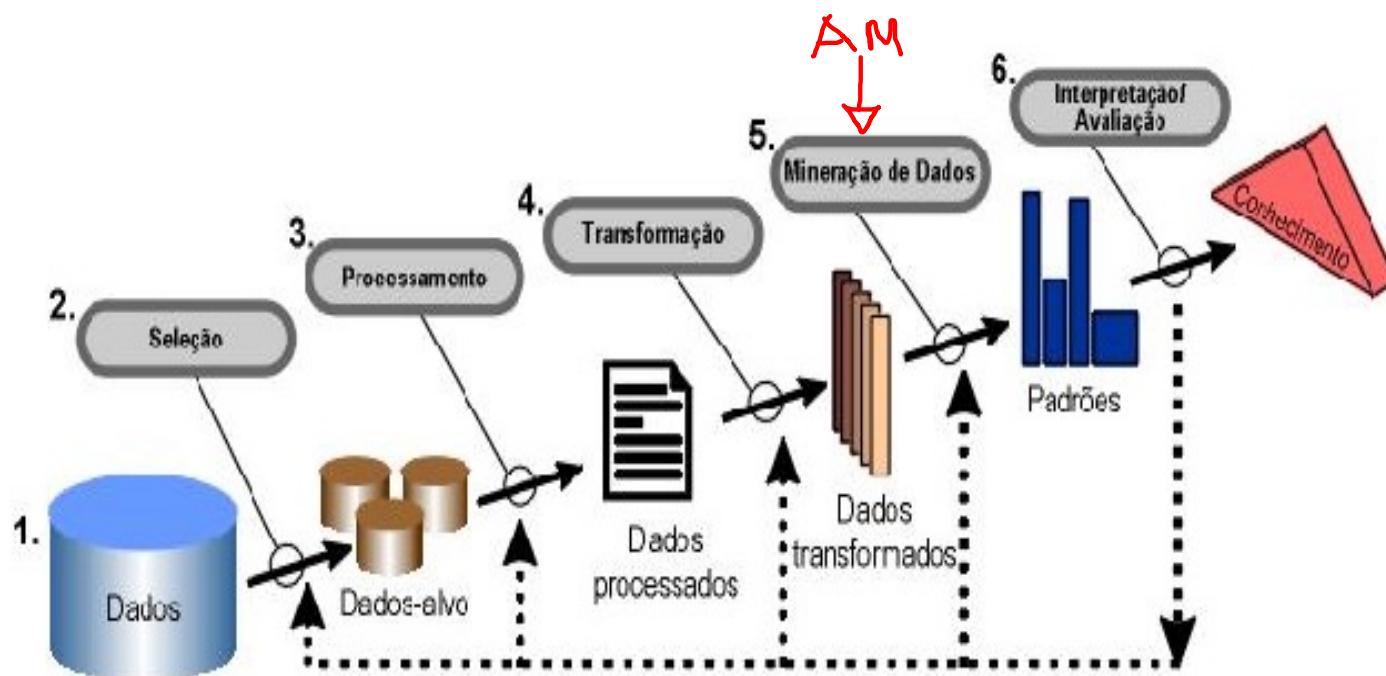
Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos de Avaliação de Risco de crédito:**
- **4 atributos e 3 classes** (Baseado no livro do Luger: IA)

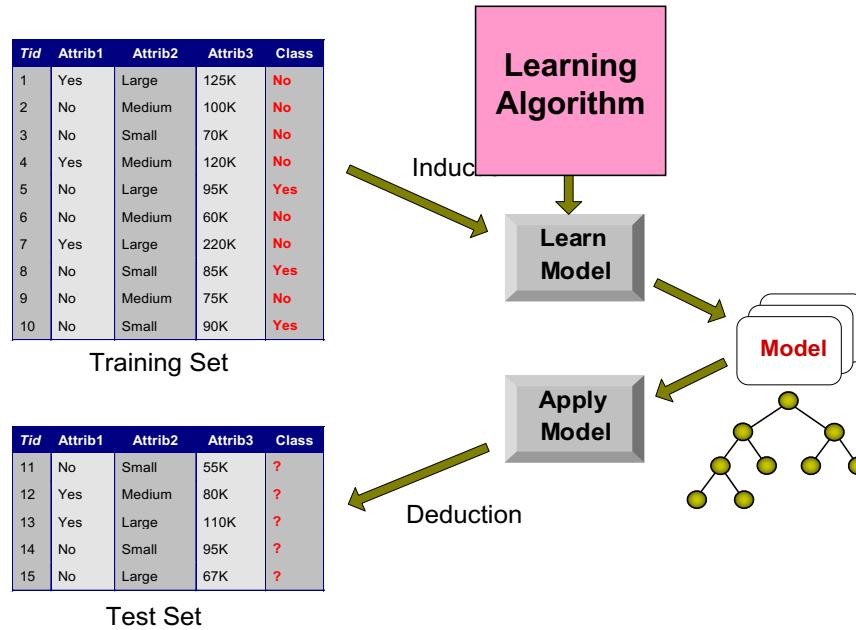
	Historia de Crédito	Dívida	Garantia	Renda	Risco
E1	Ruim	Alta	Nenhuma	\$0 a \$15k	Alto
E2	Desconhecida	Alta	Nenhuma	\$15 a \$35k	Alto
E3	Desconhecida	Baixa	Nenhuma	\$15 a \$35k	Moderado
E4	Desconhecida	Baixa	Nenhuma	\$0 a \$15k	Alto
E5	Desconhecida	Baixa	Nenhuma	Acima de \$35k	Baixo
E6	Desconhecida	Baixa	Adequada	Acima de \$35k	Baixo
E7	Ruim	Baixa	Nenhuma	\$0 a \$15k	Alto
E8	Ruim	Baixa	Adequada	Acima de \$35k	Moderado
E9	Boa	Baixa	Nenhuma	Acima de \$35k	Baixo
E10	Boa	Alta	Adequada	Acima de \$35k	Baixo
E11	Boa	Alta	Nenhuma	\$0 a \$15k	Alto
E12	Boa	Alta	Nenhuma	\$15 a \$35k	Moderado
E13	Boa	Alta	Nenhuma	Acima de \$35k	Baixo
E14	Ruim	Alta	Nenhuma	\$15 a \$35k	Alto

Etapas do Processo KDD

Fonte: FAYYAD; PIATETSKY-SHAPIRO; SMYTH, 1996



AD de Classificação



Contexto da aula em relação à arquitetura conceitual

Foco: Componente **Base de Conhecimento (BC)** da arquitetura conceitual para um Agente Baseado em Conhecimento.

Técnica: Uso de aprendizagem de máquina (**AM**) supervisionada.

Técnica a ser aprendida: Aprendizagem de Árvore de Decisão (**AD**), usando inferência indutiva.

Propósito central da aula

Como construir automaticamente, usando técnica de AM, uma **base de conhecimento (BC)** a partir de **dados**, considerando tal **BC** como um componente de um **agente baseado em conhecimento?**

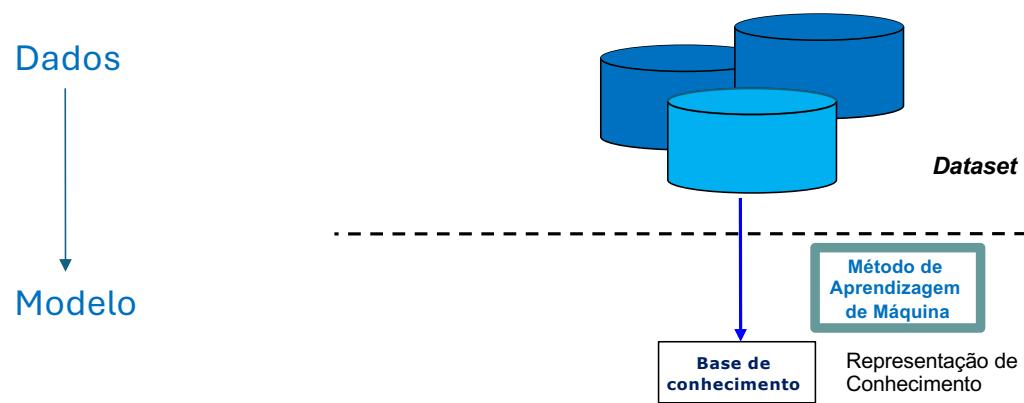
Aprendizagem de Máquina Supervisionada

Dados → Modelo: AD (Base de Conhecimento)



Árvore de Decisão ou regras, ...

Construção Automática da Base Conhecimento



Aprendizagem de AD

- Iterative Dichotomizer

- Algoritmo ID3 (Quinlan 1986)

```
function APRENDIZAGEM_DA_ID3(exemplos, atributos, default) : árvore de decisão
    Se (exemplos é vazio)
        então return default
    senão if (todos os exemplos têm a mesma classificação)
        então return (a classificação)
    senão Se (atributos é vazio)
        então return maioria(exemplos)
    senão melhor <- ESCOLHA_MELHOR_ATRIBUTO(atributos, exemplos)
        árvore <- nova árvore com raiz “melhor”
        Para cada valor  $v_i$  de melhor faça
            exemplos $_i$  <- exemplos onde melhor =  $v_i$ 
            subárvore <- APRENDIZAGEM_DA_ID3(exemplos $_i$ ,
                                              atributos - {melhor},
                                              maioria(exemplos))
            adicione subárvore como um ramo à árvore com rótulo  $v_i$ 
        return árvore;
```

Qual Atributo é o melhor classificador?

Qual atributo deve ser selecionado como o **mais informativo** para classificar os exemplos?

Articular as noções de Entropia e Ganho de Informação.

Há 2 passos para calcular o ganho de informação para cada atributo

- Calcular entropia do “target”.
- Calcular a entropia de cada atributo.

Qual Atributo é o melhor classificador?

Qual atributo deve ser selecionado como o **mais informativo** para classificar os exemplos?

Qual atributo deve ser testado na raiz da árvore?"

- Para responder esta questão, cada atributo da instância é avaliado usando um teste estatístico para determinar quão bem ele **sozinho** classifica os exemplos de treinamento.

O **melhor atributo** é selecionado e usado como teste na **raiz** da árvore.

Um descendente do nó raiz é então criado para cada valor possível deste atributo e os exemplos de treinamento são ordenados para o nó descendente apropriado.

Cálculo de Entropia e Ganho de Informação

Cálculo de Entropia

$$\text{Entropy} = -\sum_{i=1}^n p_i \log_2(p_i)$$

Cálculo do **Ganho de informação**

Ganho de Informação: Decréscimo de Entropia, com a **Partição de S**

Ganho de informação de um **atributo A** em relação a um conjunto **S**:

$$\mathbf{GI}(S, A) = E(S) - \sum_{v \in \mathbf{Valores}(A)} \frac{|S_v|}{|S|} E(S_v)$$

Onde:

v : valores possíveis para A

S_v : Subconjunto de S em que o valor de A é igual a v

$|S|$: n^o de elementos de S

**Exemplo de Construção
de uma
Árvore de Decisão para o
conjunto de dados a seguir**

Indução de Árvore de Decisão

- Ex.: Conjunto de Exemplos (treinamento) sobre Jogar Tênis:
 - 4 atributos e 2 classes (Baseado no livro do Tom Mitchell)

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Entropia da Classe para a Coleção de Exemplos: E(S)

- *A Entropia de S relativa a essa classificação booleana é dada por:*

$$\text{Entropy} = -\sum_{i=1}^n p_i * \log_2(p_i)$$

$$Entropia(S) = Entropia (PlayTennis) = Entropia [9_{yes}, 5_{no}]$$

Indução de Árvore de Decisão

- Ex.: Conjunto de Exemplos sobre Jogar Tenis:
- 4 atributos e 2 classes (Baseado no livro do Tom Mitchell)

Day	PlayTennis
D1	No
D2	No
D3	Yes
D4	Yes
D5	Yes
D6	No
D7	Yes
D8	No
D9	Yes
D10	Yes
D11	Yes
D12	Yes
D13	Yes
D14	No

- A Entropia de S relativa a essa classificação booleana é dada por

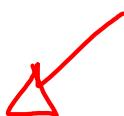
$$\text{Entropy} = -\sum_{i=1}^n p_i * \log_2(p_i)$$

Primeiramente, calculamos a entropia do target (PlayTennis), isto é, a Entropia da Classe para o CT, como a seguir.

Indução de Árvore de Decisão

- Ex.: Conjunto de Exemplos sobre Jogar Tenis:
- 4 atributos e 2 classes (Baseado no livro do Tom Mitchell)

Day	PlayTennis
D1	No
D2	No
D3	Yes
D4	Yes
D5	Yes
D6	No
D7	Yes
D8	No
D9	Yes
D10	Yes
D11	Yes
D12	Yes
D13	Yes
D14	No



$$Entropia(S) = Entropia(PlayTennis) = Entropia[9_{yes}, 5_{no}]$$

$$\begin{aligned} Entropia(PlayTennis) &= -(9/14) \times \log_2(9/14) - (5/14) \\ \log_2(5/14) &= 0.940 \end{aligned}$$



$$Yes = 9/14, \quad No = 5/14$$

Indução de Árvore de Decisão

- Ex.: Conjunto de Exemplos sobre Jogar Tenis:
- 4 atributos e 2 classes (Baseado no livro do Tom Mitchell)

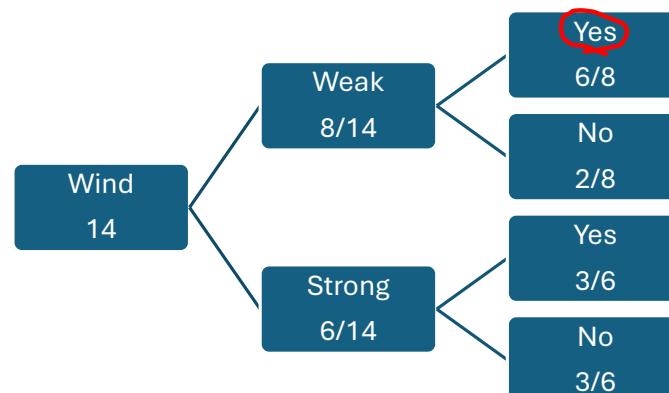
Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Ganho de Informação: Cálculo de $info_x(S)$

Ganho de Informação
com o
atributo Wind

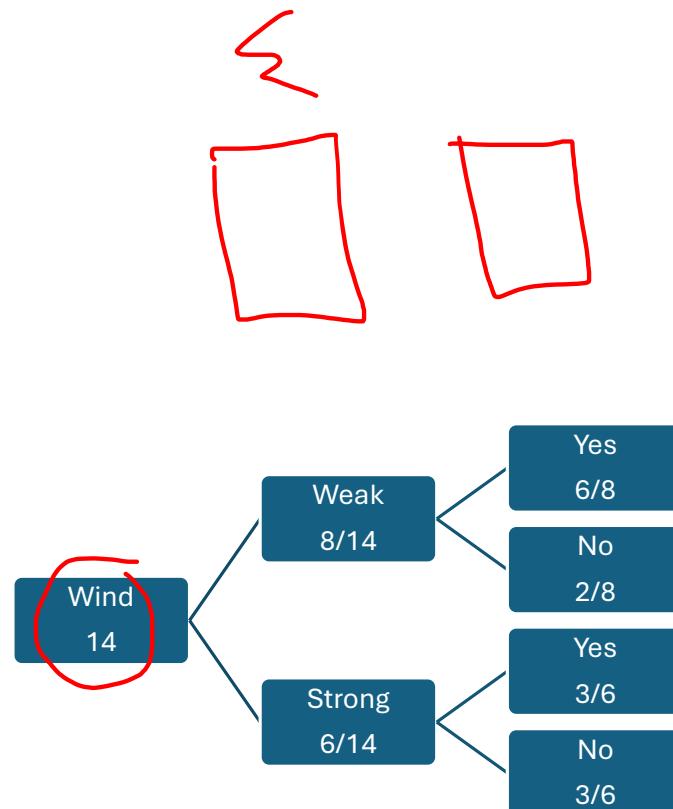
Wind

Wind	PlayTennis
Weak	No
Strong	No
Weak	Yes
Weak	Yes
Weak	Yes
Strong	No
Strong	Yes
Weak	No
Weak	Yes
Weak	Yes
Strong	Yes
Strong	Yes
Weak	Yes
Strong	No



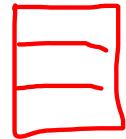
Wind

Wind	PlayTennis
Weak	No
Strong	No
Weak	Yes
Weak	Yes
Weak	Yes
Strong	No
Strong	Yes
Weak	No
Weak	Yes
Weak	Yes
Strong	Yes
Strong	Yes
Weak	Yes
Strong	No



Wind + weak

Wind	PlayTennis
Weak	No
Weak	Yes
Weak	Yes
Weak	No
Weak	Yes
Weak	Yes
Weak	Yes



$\sum \pi_i \log_2 \pi_i$



Wind = Weak (8/14), tendo $S_{weak} \leftarrow [6_{yes}, 2_{no}]$
ou seja,

6/8 PlayTennis = yes, e 2/8 PlayTennis = no

$$Entropia(S_{weak}) = -(6/8) \log_2(6/8) - (2/8) \log_2(2/8) \\ = 0,811$$

Wind + Strong



Wind	PlayTennis
Strong	No
Strong	No
Strong	Yes
Strong	Yes
Strong	Yes
Strong	No



Wind = Strong (6/14), tendo $S_{\text{strong}} \leftarrow [3_{\text{yes}}, 3_{\text{no}}]$ ou seja,

3/6 PlayTennis = Yes e 3/6 PlayTennis = No

$$\begin{aligned} \text{Entropia } (S_{\text{strong}}) &= -(3/6) \log_2(3/6) - (3/6) \log_2(3/6) \\ &= 1,00 \end{aligned}$$



Ganho de Informação: Cálculo de $\text{info}_x(S)$

- AD: **Entropia da Partição segundo o atributo Wind**
- Entropia para Wind = Weak e para Wind = Strong

$$\text{Entropia}(S_{\text{weak}}) = -(6/8) \log_2(6/8) - (2/8) \log_2(2/8) = 0,811$$

$$\text{Entropia}(S_{\text{strong}}) = -(3/6) \log_2(3/6) - (3/6) \log_2(3/6) = 1,00$$

Portanto,

$$\text{GI}(S, A) = E(S) - \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} E(S_v)$$

$$\text{Ganho}(S, \text{Wind}) = \text{Entropia}(S) - \sum_{v \in \{\text{Weak}, \text{Strong}\}} \frac{|S_v|}{|S|} \text{Entropia}(S_v)$$

$$\text{Ganho}(S, \text{Wind}) = 0,940 - \frac{8}{14} \times \text{Entropia}(S_{\text{weak}}) - \frac{6}{14} \times \text{Entropia}(S_{\text{strong}})$$

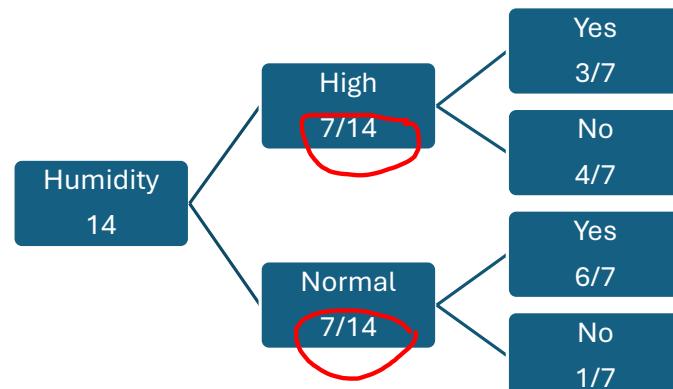
$$\text{Ganho}(S, \text{Wind}) = 0,940 - \frac{8}{14} \times 0,811 - \frac{6}{14} \times 1,00 = 0,048$$

Ganho de Informação: Cálculo de $info_x(S)$

**Ganho de Informação
com o
atributo Humidity**

Humidity

Humidity	PlayTennis
High	No
High	No
High	Yes
High	Yes
Normal	Yes
Normal	No
Normal	Yes
High	No
Normal	Yes
Normal	Yes
Normal	Yes
High	Yes
Normal	Yes
High	No



Humidity + High

Humidity	PlayTennis
High	No
High	No
High	Yes
High	Yes
High	No
High	Yes
High	No



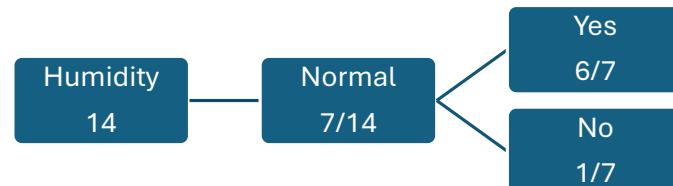
Humidity = High (7/14), tendo $S_{high} \leftarrow [3_{yes}, 4_{no}]$ ou seja,

3/7 PlayTennis = Yes, e 4/7 PlayTennis = No

$$Entropia(S) = -(3/7) \log_2(3/7) - (4/7) \log_2(4/7) = 0,985$$

Humidity + Normal

Humidity	PlayTennis
Normal	Yes
Normal	No
Normal	Yes
Normal	Yes
Normal	Yes
Normal	Yes
Normal	Yes



Humidity = **Normal (7/14)**, tendo
 $S_{normal} \leftarrow [6_{yes}, 1_{no}]$ ou seja,

6/7 PlayTennis = Yes, e **1/7 PlayTennis = No**

Entropia(S) = $-(6/7) \log_2(6/7) - (1/7) \log_2(1/7) = 0,592$

Ganho de Informação: Cálculo de $info_x(S)$

- AD: Entropia da Partição segundo o atributo Humidity
- Entropia para Humidity = High e para Humidity = Normal

$$Entropia(S_{high}) = -(3/7) \log_2(3/7) - (4/7) \log_2(4/7) = 0,985$$

$$Entropia(S_{normal}) = -(6/7) \log_2(6/7) - (1/7) \log_2(1/7) = 0,592$$

Portanto,

$$\text{Ganho}(S, \text{Humidity}) = \text{Entropia}(S) - \sum_{v \in \text{Valores}(A)} (|S_v|/|S|) \text{Entropia}(S_v)$$

$v \in \text{Valores}(A)$

$$\text{Ganho}(S, \text{Humidity}) = 0,940 - (7/14) \times \text{Entropia}(S_{high}) - (7/14) \times \text{Entropia}(S_{normal})$$

$$\text{Ganho}(S, \text{Humidity}) = 0,940 - (7/14) \times 0,985 - (7/14) \times 0,592 = 0,151$$

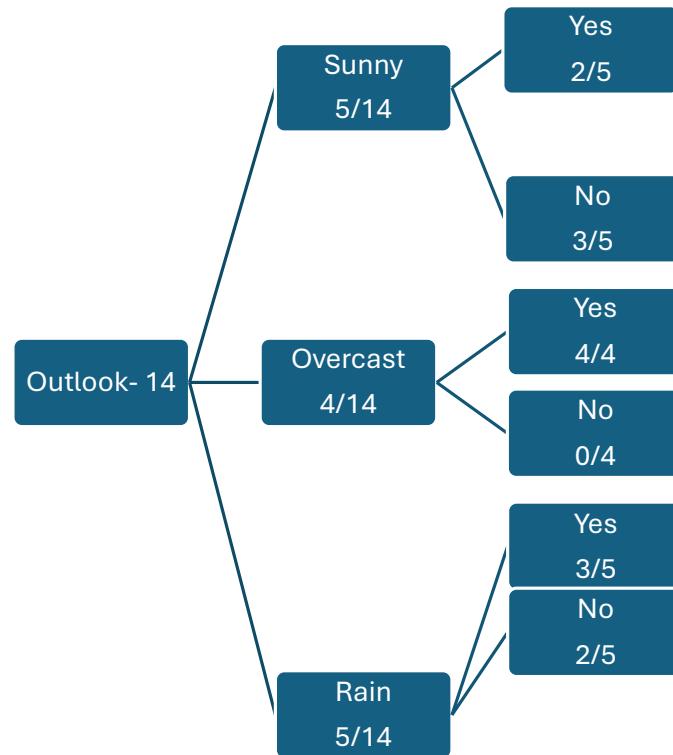
Ganho de Informação: Cálculo de $info_x(S)$

**Ganho de Informação
com o
atributo Outlook**

Outlook

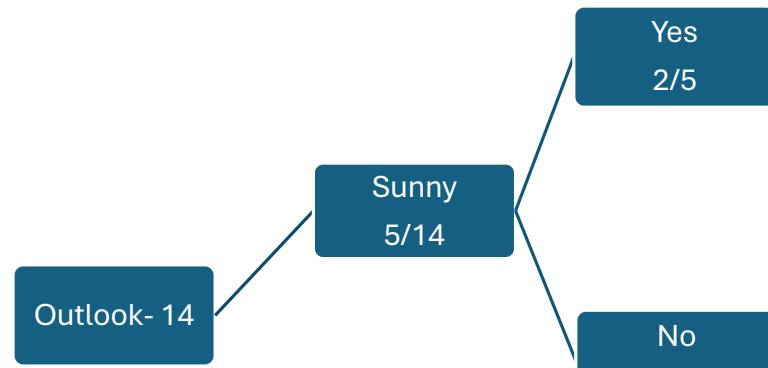


Outlook	PlayTennis
Sunny	No
Sunny	No
Overcast	Yes
Rain	Yes
Rain	Yes
Rain	No
Overcast	Yes
Sunny	No
Sunny	Yes
Rain	Yes
Sunny	Yes
Overcast	Yes
Overcast	Yes
Rain	No



Outlook + Sunny

Outlook	PlayTennis
Sunny	No
Sunny	No
Sunny	No
Sunny	Yes
Sunny	Yes



Entropia (S_{Sunny}) = 0,971

Ganho de informação com atributo = Outlook

$$\text{Ganho}(S, \text{Outlook}) = \text{Entropia}(S) - \sum (|S_v|/|S|) \text{Entropia}(S_v)$$

$$\text{Ganho}(S, \text{Outlook}) = 0,940 - (5/14) \times \underline{\text{Entropia}(S_{\text{sunny}})} - (4/14) \times \underline{\text{Entropia}(S_{\text{overcast}})} - (5/14) \times \underline{\text{Entropia}(S_{\text{rainy}})}$$

$$\text{Ganho}(S, \text{Outlook}) = 0,940 - (5/14) \times 0,971 - (4/14) \times 0,0 - (5/14) \times 0,971$$

$$\text{Ganho}(S, \text{Outlook}) = 0,940 - 0,693 = 0,247$$

Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos sobre Jogar Tenis:**
- **4 atributos e 2 classes** (Baseado no livro do Tom Mitchell)

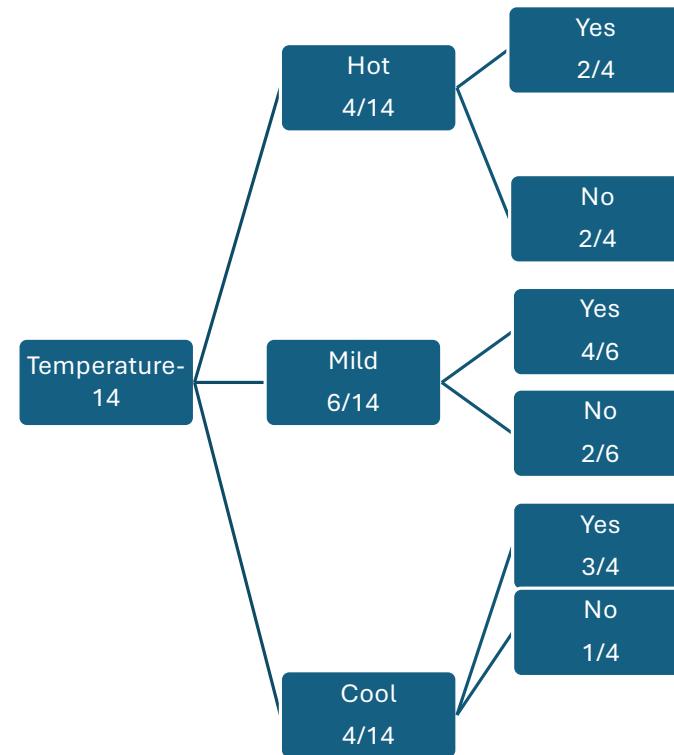
Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Ganho de Informação: Cálculo de $info_x(S)$

**Ganho de Informação
com o
atributo Temperature**

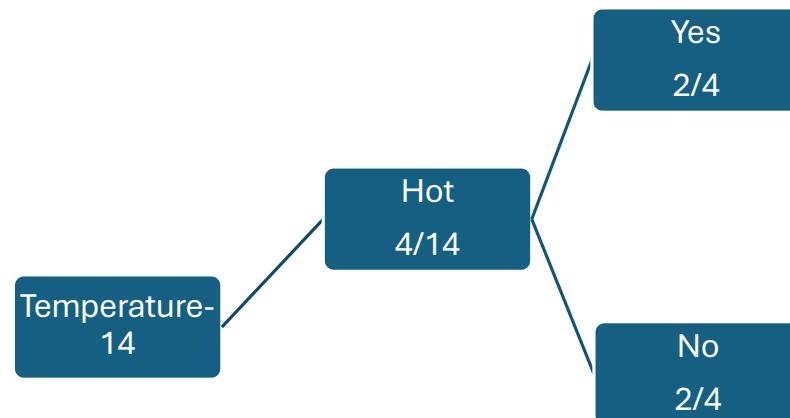
Temperature

Temperature	PlayTennis
Hot	No
Hot	No
Hot	Yes
Mild	Yes
Cool	Yes
Cool	No
Cool	Yes
Mild	No
Cool	Yes
Mild	Yes
Mild	Yes
Mild	Yes
Hot	Yes
Mild	No



Temperature + Hot

Temperature	PlayTennis
Hot	No
Hot	No
Hot	Yes
Mild	Yes
Cool	Yes
Cool	No
Cool	Yes
Mild	No
Cool	Yes
Mild	Yes
Mild	Yes
Mild	Yes
Hot	Yes
Mild	No



$$\text{Entropia}(S_{\text{hot}}) = -(2/4)\log(2/4) - (2/4)\log(2/4) = 1$$

Temperature + Mild

Temperature	PlayTennis
Hot	No
Hot	No
Hot	Yes
Mild	Yes
Cool	Yes
Cool	No
Cool	Yes
Mild	No
Cool	Yes
Mild	Yes
Mild	Yes
Mild	Yes
Hot	Yes
Mild	No



Temperature + Cool

Temperature	PlayTennis
Hot	No
Hot	No
Hot	Yes
Mild	Yes
Cool	Yes
Cool	No
Cool	Yes
Mild	No
Cool	Yes
Mild	Yes
Mild	Yes
Mild	Yes
Hot	Yes
Mild	No

Temperature-
14

Cool
4/14

Yes
3/4
No
1/4

Ganho de informação com atributo = Temperature

$$\text{Ganho}(S, \text{Temperature}) = \text{Entropia}(S) - \sum (|S_v|/|S|) \text{ Entropia}(S_v)$$

$$\text{Ganho}(S, \text{Temperature}) = 0,940 - (4/14) \times \text{Entropia}(S_{\text{hot}}) - (6/14) \times \text{Entropia}(S_{\text{mild}}) - (4/14) \times \text{Entropia}(S_{\text{cool}})$$

$$\text{Ganho}(S, \text{Temperature}) = 0,940 - (4/14) \times ?? - (6/14) \times ?? - (4/14) \times ??$$

$$\text{Ganho}(S, \text{Temperature}) = 0,940 - ?? = 0,029$$

Cálculo do Ganho de Informação em PlayTennis

- Ganho de informação para todos os 4 atributos são:

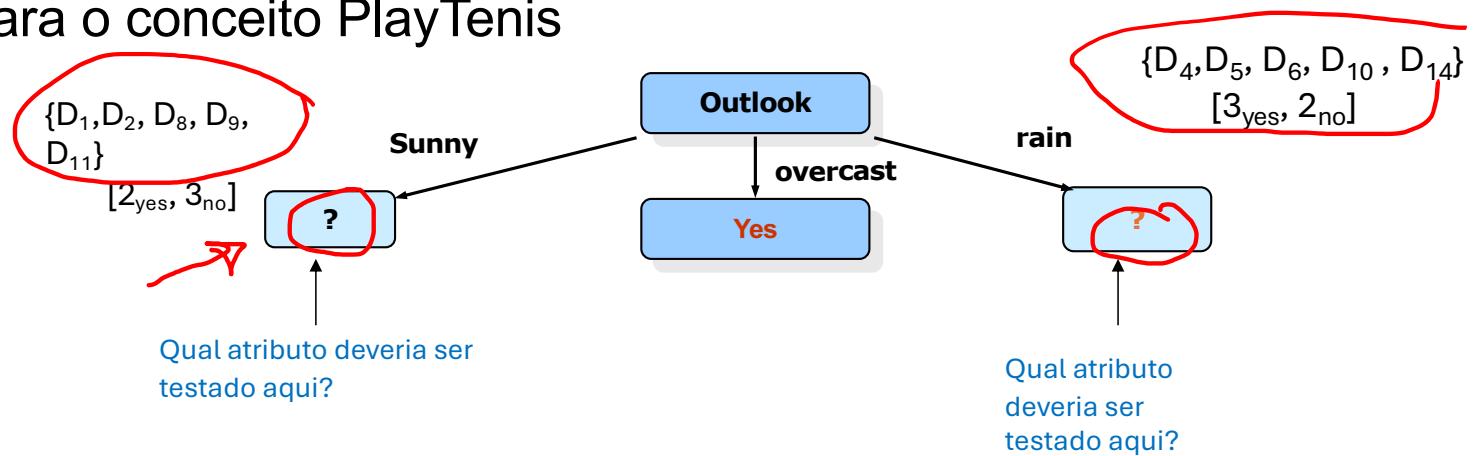
$$\left. \begin{array}{l} \text{Ganho}(S, \text{Outlook}) = \underline{\underline{0.246}} \\ \text{Ganho}(S, \text{Humidity}) = \underline{\underline{0.151}} \\ \text{Ganho}(S, \text{Wind}) = \underline{\underline{0.048}} \\ \text{Ganho}(S, \text{temperature}) = \underline{\underline{0.029}} \end{array} \right\}$$

onde S denota a coleção de exemplos de treinamento da tabela dada.

Portanto, *Outlook* fornece o maior ganho de informação e assim será raiz da árvore, i.e., *Outlook* provê a melhor predição do atributo alvo.

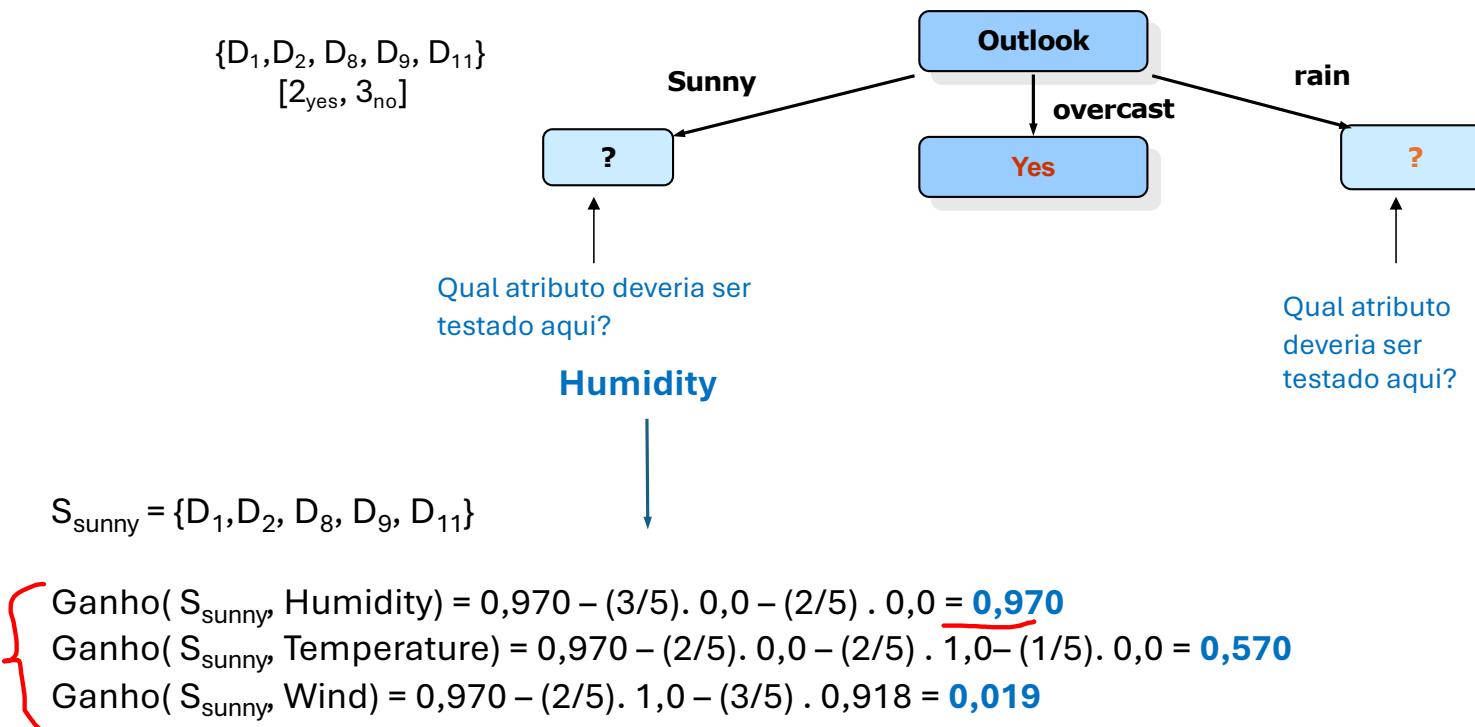
Representação de uma Árvore de Decisão para PlayTennis

- Ex.: Uma AD para o conceito PlayTenis



Representação de uma Árvore de Decisão

- Ex.: A DT for the concept PlayTenis



Portanto, **Humidity** vai ser selecionado, pois é o atributo que apresenta maior ganho de informação

Cálculo do Ganho de Informação em PlayTennis

- Ganho de informação para todos os 3 atributos são:

$$\text{Ganho}(S_{\text{sunny}}, \text{Humidity}) = 0.970$$

$$\text{Ganho}(S_{\text{sunny}}, \text{Temperature}) = 0.570$$

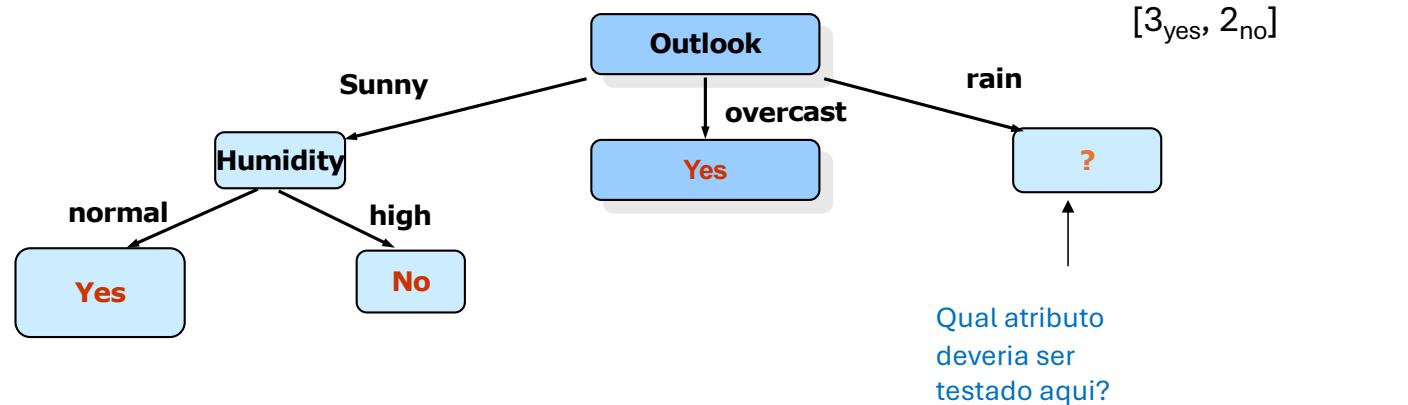
$$\text{Ganho}(S_{\text{sunny}}, \text{Wind}) = 0.019$$

onde S_{sunny} denota a coleção de exemplos de treinamento da tabela dada.

Portanto, *Humidity* fornece o maior ganho de informação e assim será raiz dessa árvore (subárvore), i.e., *Humidity* provê a melhor predição do atributo alvo.

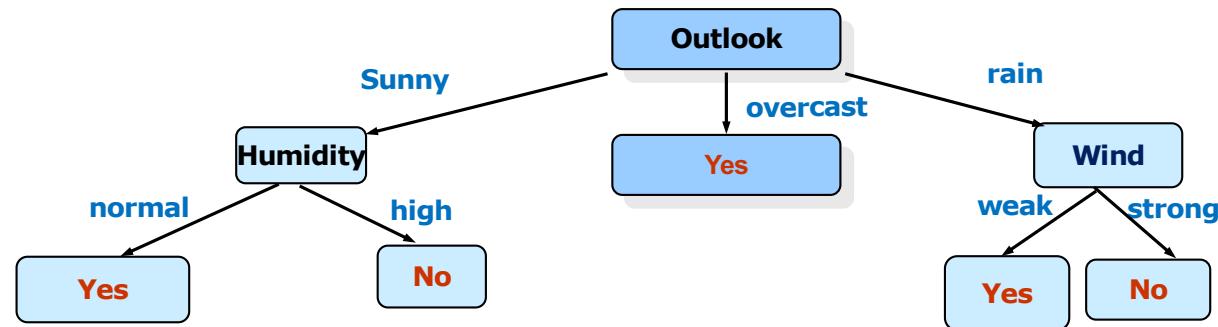
Representação de uma Árvore de Decisão

- Ex.: A DT for the concept PlayTennis



Representação de uma Árvore de Decisão

- Ex.: A DT for the concept PlayTennis



Um Problema Motivador: Retorno ...

Suponha que um gerente de um determinado banco, contratasse você, para desenvolver um Sistema Inteligente para cumprir a tarefa de decidir sobre o nível de risco oferecido por usuários que buscam empréstimo de dinheiro, a cada demanda de seus clientes.

Considere 3 categorias de risco na **classificação** dos clientes: **Alto**, **Moderado** e **Baixo**.

Em Busca da Solução

- Do ponto de vista técnico e agora já sabendo que se trata de uma tarefa de **Classificação**, envolvendo **aprendizado de máquina** (Machine Learning), por onde iniciar?

Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos de Avaliação de Risco de crédito:**
- **4 atributos e 3 classes** (Baseado no livro do Luger: IA)

	Historia de Crédito	Dívida	Garantia	Renda	Risco
E1	Ruim	Alta	Nenhuma	\$0 a \$15k	Alto
E2	Desconhecida	Alta	Nenhuma	\$15 a \$35k	Alto
E3	Desconhecida	Baixa	Nenhuma	\$15 a \$35k	Moderado
E4	Desconhecida	Baixa	Nenhuma	\$0 a \$15k	Alto
E5	Desconhecida	Baixa	Nenhuma	Acima de \$35k	Baixo
E6	Desconhecida	Baixa	Adequada	Acima de \$35k	Baixo
E7	Ruim	Baixa	Nenhuma	\$0 a \$15k	Alto
E8	Ruim	Baixa	Adequada	Acima de \$35k	Moderado
E9	Boa	Baixa	Nenhuma	Acima de \$35k	Baixo
E10	Boa	Alta	Adequada	Acima de \$35k	Baixo
E11	Boa	Alta	Nenhuma	\$0 a \$15k	Alto
E12	Boa	Alta	Nenhuma	\$15 a \$35k	Moderado
E13	Boa	Alta	Nenhuma	Acima de \$35k	Baixo
E14	Ruim	Alta	Nenhuma	\$15 a \$35k	Alto

Árvore de Decisão

- Ex.: Avaliação de Risco de crédito

